

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 2

По дисциплине « Обработка изображений в интеллектуальных системах »
Тема: «Конструирование моделей на базе предобученных нейронных сетей»

Выполнил:
Студент 4 курса
Группы ИИ-26
Рудь В.В.
Проверил:
Андренко К.В.

Вариант 15


Цель: осуществлять обучение НС, сконструированных на базе предобученных архитектур НС




Задачи лабораторной работы



1. Для заданной выборки и архитектуры предобученной нейронной организовать процесс обучения НС, предварительно изменив структуру слоев, в соответствии с предложенной выборкой. Использовать тот же оптимизатор, что и в ЛР №1. Построить график изменения ошибки и оценить эффективность обучения на тестовой выборке;
2. Сравнить полученные результаты с результатами, полученными на кастомных архитектурах из ЛР №1;
3. Ознакомиться с state-of-the-art результатами для предлагаемых выборок (по материалам в сети Интернет). Сделать выводы о результатах обучения НС из п. 1 и 2;
4. Реализовать визуализацию работы предобученной СНС и кастомной (из ЛР 1). Визуализация осуществляется посредством выбора и подачи на сеть произвольного изображения (например, из сети Интернет) с отображением результата классификации;

15	STL-10 (размеченная часть)	Adadelata	MobileNet v2
----	----------------------------	-----------	--------------

Результат:







```
=====
СРАВНЕНИЕ МОДЕЛЕЙ (ЛР №1 vs ЛР №2)
=====
Метрика                SimpleSTL10CNN        MobileNetV2
-----
Всего параметров        38,738,506            2,236,682
Обучаемых параметров    38,738,506            12,810
Оптимизатор             Adadelta (lr=1.0)     Adadelta (lr=1.0)
Test Accuracy (%)        45.14                  94.01
=====

=====
ВИЗУАЛИЗАЦИЯ НА ПРОИЗВОЛЬНЫХ ИЗОБРАЖЕНИЯХ ИЗ ИНТЕРНЕТА
=====
dog      | MobileNetV2: dog      ( 98.6%) | Custom: monkey      ( 85.4%)
cat      | MobileNetV2: cat      (100.0%) | Custom: bird        ( 44.9%)
ship     | MobileNetV2: car      ( 51.1%) | Custom: airplane    ( 52.6%)
airplane | MobileNetV2: airplane ( 97.8%) | Custom: bird        ( 42.4%)
car      | MobileNetV2: car      (100.0%) | Custom: truck       ( 84.0%)

Process finished with exit code 0
|
```

Вывод: В ходе работы была обучена предобученная нейронная сеть MobileNetV2 (на базе весов ImageNet) для классификации изображений датасета STL-10 (размеченная часть, 5000 изображений). Структура сети была адаптирована под 10 классов заменой финального классификатора, feature extractor заморожен. Использовался оптимизатор Adadelta — тот же, что и в ЛР №1.

Основные результаты:

Модель	Обучаемых параметров	Test Accuracy
SimpleSTL10CNN (ЛР №1, с нуля)	38,738,506	45.16%
MobileNetV2 (ЛР №2, pretrained)	12,810	93.97%

Предобученная MobileNetV2 показала точность 93.97%, превзойдя кастомную CNN из ЛР №1 на 48.8 п.п., при этом обучалось в 3 024 раза меньше параметров. Это наглядно демонстрирует эффективность transfer learning: признаки, выученные на 1.2 млн изображений ImageNet, позволяют достичь высокой точности даже на малом датасете (5000 примеров) и за меньшее число эпох (25 против 25, но с существенно лучшей сходимостью).

Визуализация на 5 произвольных изображениях из Интернета подтвердила результаты: MobileNetV2 корректно классифицировала 4 из 5 изображений с уверенностью 91–100%, тогда как кастомная модель не дала ни одного правильного ответа, что объясняется недостаточным объёмом обучающих данных и отсутствием предобученных признаков.

Сравнение с SOTA: полученный результат (93.97%) близок к современным state-of-the-art методам для STL-10 (полный fine-tuning MobileNetV2 ~95–96%, semi-supervised MixMatch ~94%). Оставшийся разрыв объясняется отсутствием тонкой настройки свёрточных слоёв и неиспользованием 100 000 неразмеченных изображений STL-10, доступных для semi-supervised подходов.

Таким образом, цель работы достигнута: предобученные архитектуры показывают значительное преимущество перед обучением с нуля на малых выборках, что подтверждает практическую ценность transfer learning в задачах компьютерного зрения.